北京航空航天大學
BEIHANG UNIVERSITY

计算机网络研究性实验

BGP 协议功能的设计与实现

专 业 名 称 计算机科学与技术（创新实验班）

指 导 老 师 张力军

学 生 姓 名 胡京徽

学 生 学 号 11061191

2014 年 7 月 10 日

摘要

本文介绍了笔者在 GNU/Linux 环境下，根据 rfc1771 文档，通过网络编程接口实现的 BGP 协议模拟器。

文中首先着重分析了 BGP 报文的格式和相关作用，同时详细解读了 BGP 协议的有限状态机的结构。然后，给出了笔者对将要实现的系统设计思路。接着给出了笔者实现 BGP 协议的相关细节。最后给出了笔者在 GNU/Linux 实际环境中的测试报告。

论文主体分为五章，章节安排如下

第一章，说明课题的来源及研究目标

第二章，解读 BGP 协议相关内容

第三章，对系统的设计进行详细说明

第四章，对系统的实现进行详细说明

第五章，对实现的测试进行说明

最后是笔者的个人总结。

关键字：BGP，rfc1771，GNU/Linux，网络编程

目录

第一章 绪论

1.1 课题来源

该课题是 2014 年北航大三计算机科学与技术网络提高层次众多选题之中的一个，主要是要求学生独立地对边界网关协议（BGP）的研究与实现。

边界网关协议（BGP）是运行于 TCP 上的一种自治系统的路由协议。 BGP 是唯一一个用来处理像因特网大小的网络的协议，也是唯一能够妥善处理好不相关路由域间的多路连接的协议。 BGP 构建在 EGP 的经验之上。 BGP 系统的主要功能是和其他的 BGP 系统交换网络可达信息。网络可达信息包括列出的自治系统（AS）的信息。这些信息有效地构造了 AS 互联的拓朴图并由此清除了路由环路，同时在 AS 级别上可实施策略决策。

当时笔者出于兴趣，参与到这个课题中。从头实现一个简单的 BGP 协议，同时可以学会了在 GNU/Linux 下网络编程技巧，受益良多。

1.2 课题要求

1. 学习 BGP 协议，了解 BGP 协议的原理；
2. 基于 Linux 实现基本的 BGP 协议；
3. 实现 BGP 协议规定格式数据的封装发送；
4. 接受符合 BGP 协议规定格式的数据包，并进行逻辑处理；
5. 根据 BGP 原理生成单播路由表，并使得单播数据包能根据路由表进行转发；
6. 需识别携带基本路由属性的报文种类。

1.3 项目管理

笔者将项目的代码托管在 CSDN 上，工程首页快速链接 https://code.csdn.net/jeanhwea/bgpsim

开发环境：

ubuntu10.04	Kdevelop4	g++ 4.6	gdb 7.4

第二章 BGP 协议研究

2.1 BGP 协议的简介

边界网关协议（BGP）是自治系统间路由协议。它的建立来源于 RFC904[1]中定义的 EGP 以及 RFC1092[2]和 RFC1093[3]中描述的 EGP 在 NSFNET 骨干网中的使用。

BGP 交互系统的主要功能是和其他的 BGP 系统交换网络可达信息。网络可达信息包括可达信息经过的自治系统（AS）清单上的信息。这些信息有效地构造了 AS 互联的图像并由此清除了路由环路同时在 AS 级别上实施了策略决策。

BGP-4 提供了一套新的机制支持无类域间路由。这些机制包括支持网络前缀的广播取消 BGP 网络中“类”的概念。BGP-4 也引入机制支持路由聚合，包括 AS 路径的聚合。这些改变为[8, 9]建议的超网方案提供了支持。

为了刻画 BGP 执行的路由决策，集中讲述 BGP 发言者通告他自己使用的路由到相邻 AS 中对端（与之通信的别的 BGP 发言者）的规则。这些规则反映了当今互联网广泛使用的“一跳一跳”路由范例。注意一些策略不被“一跳一跳路由范例支持所以需要比如源路由之类的技术来增强。例如，BGP 不支持 AS 发送流量到相邻的 AS 但是路由和源自相邻 AS 流量有不同的路由。另一方面，BGP 支持任何与“一跳一跳”一致的策略。由于当前互联网只使用“一跳一跳”路由范例同时 BGP 支持与范例一致的策略，BGP 作为 AS 间路由协议非常适用于当今互联网。

2.2 BGP 报文格式

2.2.1 报文首部格式

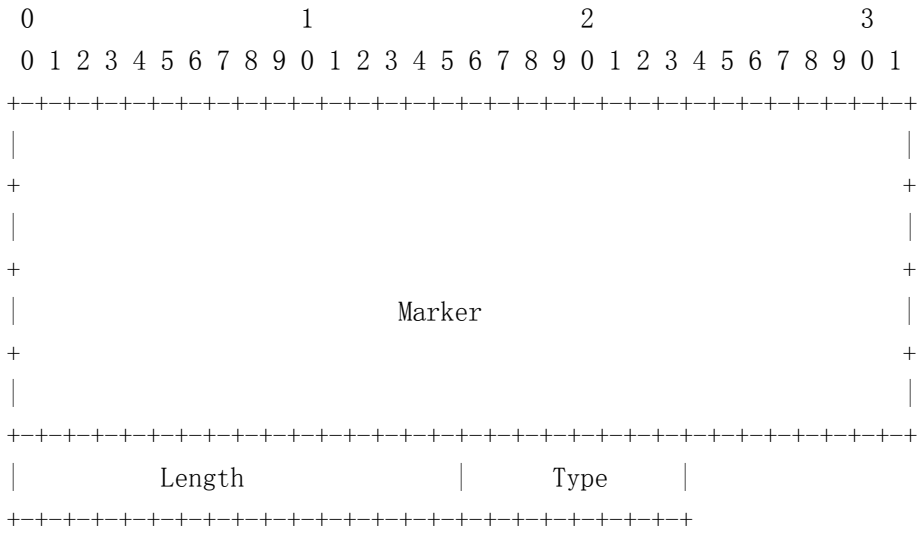

Marker（标记）：

本 16 字节的域包含报文接收者可以预测的值。如果报文类型是 OPEN，或者 OPEN 报文承载了认证信息（作为可选参数），标记必须是全 1。否者，标记的值要使用认证机制来计算（认证机制是通过认证信息的一部分来指定的）。标记可以用来探测 BGP 对端的同步丢失，认证进入的 BGP 报文。

长度(Length):

两字节无符号整数指定了报文的字节全长，包括头部的字节。这也就是说，允许在传输层数据流定位下一个报文（的标记域）。长度的值必须最少 19 字节最大 4096 字节，同时由于不同的报文有更多的约束。不允许“填充”多余的数据在报文后，所以长度域是需要的最小值。

类型（Type）：

一字节的无符号整数制定了报文类型编码。如下定义：

1 - OPEN

2 - UPDATE

3 - NOTIFICATION

4 – KEEPALIVE

2.2.2 OPEN 报文格式

在传输协议连接建立之后，两边发送的第一个报文是 OPEN 报文。如果 OPEN 报文可以接受，需要发回一个 KEEPALIVE 报文来确认 OPEN 报文。一旦确认了 OPEN 报文，UPDATE，KEEKPALIVE 和 NOTIFICATION 报文可以交换。

在定长的 BGP 报文头后面，OPEN 报文包含下列域：

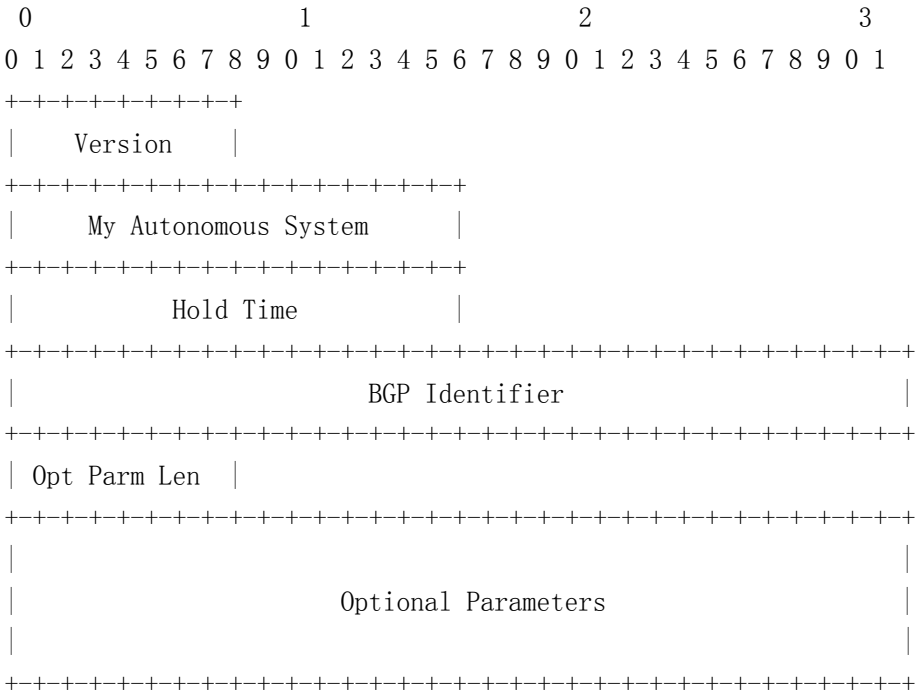

Version（版本）：

1 字节无符号整数指示报文的协议版本号。当前的 BGP 版本号是 4。

My Autonomous System（我的自治系统）：

2 字节无符号整数指示发送者自治系统号。

Hold Time（保持时间）：

2 字节的无符号整数指示了发送者期望的 Hold 计时器的秒数。在接收 OPEN 报文后，BGP 发言者必须使用配置的 Hold 计时器和收到的 Hold 计时器来计算 Hold 计时器的值。Hold 计时器必须要末是 0 要末最少 3 秒。应用可以根据 Hold 计时器来拒绝连接。计算好的值指示了在连续的 KEEPALIVE 和/或 UPDATE 报文之间可以流逝的最大秒数。

BGP Identifier (BGP 标示符):

4 字节无符号整数指示了 BGP 发言者的标示符。给定的 BGP 发言者设置 BGP 标示符为 IP 地址。在启动的时候决定 BGP 表示符，对每一个本地端口和每一个对端是一样的。

Optional Parameters Length（可选参数长度）:

1 字节无符号整数指示可选参数域的字节总长度。如果这个域是 0，说明没有可选参数。

笔者的实现中这个域为 0；

Optional Parameters（可选参数）:

这个域包含了可选参数清单，每一个参数编码为<参数类型，参数长度，参数值>三元组。

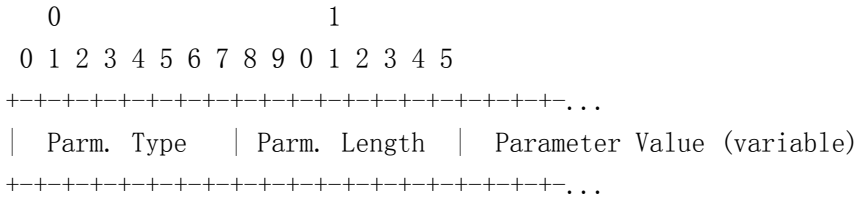

可选参数说明详细参考 rfc1771 文档。

OPEN 报文的最小长度是 29 字节（包括报文头）。

2.2.3 UPDATE 报文格式

UPDATE 报文用来发送路由信息到 BGP 对端。UPDATE 报文报内的信息可以被用来构造 AS 之间的关系描述。通过应用以下讨论的规则，路由环路和别的异常可以测出并清除出 AS 间路由。

UPDATE 报文用来广播一条可用路由到对端，或者撤销多条不可用路由。UPDATE 报文可以同时广播可用路由并撤销多个不可用路由。UPDATE 报文总是包括定长报文头，同时可选的包括下面的域：

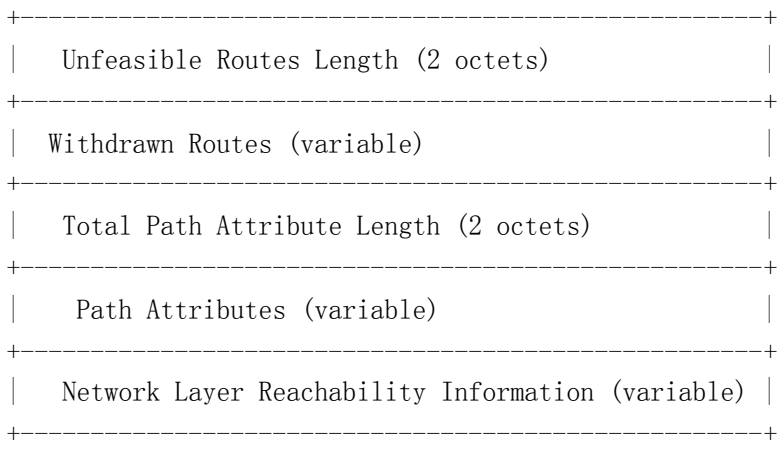

Unfeasible Routes Length（不可用路由长度）：

2 字节无符号整数指示了撤销路由的字节总长度。这个值必须保证网络层可达信息域的长度被确定。0 说明没有撤销路由， UPDATE 报文内部没有撤销路由。

Withdrawn Routes（撤销路由）：

可变长路由域包括一系列的 IP 前缀说明撤销服务的路由。每一个 IP 前缀编码为〈长度，前缀〉二元组，如下描述：

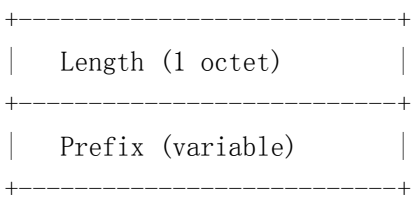

使用和含义如下：

a) Length(长度)：

长度指示了 IP 前缀的比特数。0 长度指示了匹配所有 IP 地址的前缀（前缀本身为 0 字节）

b) Prefix（前缀）：

前缀包含了 IP 地址前缀后面是填充比特保证域结尾符合字节边界。注意填充比特的值无意义。

Total Path Attribute Length（总的路径属性长度）：

2 字节无符号整数值时路径属性域字节总长度。值必须使下文中网络层可达域的长度能够被探测到。值 0 指示在 UPDATE 报文中没有网络层可达信息域。

Path Attributes（路径属性）：

在每一个 UPDATE 报文中有变长的路径属性序列。每一个路径属性是<属性类型，属性长度，属性值>变长三元组

属性类型是 2 字节域包括了属性标志字节和属性类型码字节。

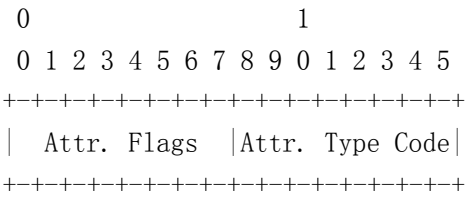

属性标志字节第一高位比特（比特 0）是可选比特。定义了属性是否是可选的（设为 1）或者是公认的（设为 0）。

属性标志字节第二高位比特（比特 1）是转发比特。定义一个可选的属性是否是转发的（如果设置为 1）或者不是转发的（设为 0）。公认属性的转发位必须设为 1。（参看部分 5 讨论转发属性）。

属性标志字节的第三比特（比特 2）是部分比特。定义是否包括在可选转发属性内的信息是部分的（设置为 1）或者是完整的（设置为 0）。公认属性和可选非转发的部分位必须是 0。

属性标志字节的第四比特（比特 3）是扩展长度比特。定义了是否属性长度是 1 字节（如果设置为 0）或者是 2 字节（如果设置为 1）。仅仅当属性值超过 255 字节的时候，扩展长度可以使用。

属性标志字节低字节顺序 4 比特没有被使用。必须填 0（接收不处理）。

如果属性标志字节的扩展长度比特被设置为 0，路径属性的第三个字节包含了属性数据的字节长度。

如果属性标志字节的扩展长度比特设置为 1，那末路径属性的第三和第四个字节包含了属性数据的字节长度。

路径属性剩下的字节代表属性值应该通过属性标识和属性类型码翻译。支持的属性类型码，它们的属性值和使用如下定义：

a) ORIGIN (类型码 1):

ORIGIN 是公认强制属性定义了路径信息的来源。本数据字节假定如下值：

值	含义
0	IGP – 网络层可达信息和来源 AS 同内部
1	EGP – 网络层可达信息通过 EGP 学习
2	INCOMPLETE – 通过别的方式学习网络层可达信息

b) AS_PATH (类型编码 2):

AS-PATH 是公认强制属性由一系列 AS 路径段组成。每一个 AS 路径段表示为三元组<路径段类型，路径段长度，路径段值>。

路径段类型是 1 字节长度域有下列定义值。

值	段类型
1	AS_SET: 在 UPDATE 报文中的路由经过的 AS 的无序集
2	AS_SEQUENCE: 在 UPDATE 报文中的路由经过的 AS 的有序集

路径段长度是 1 字节长度的域包含了在路径段值域的 AS 的数量。

路径段值域包含了一个或者多个 AS 号，每一个编码为 2 字节长度的域。

c) NEXT_HOP (类型码 3):

公认强制属性定义了作为到达 UPDATE 报文网络层可达域地址所用的下一跳的边界路由器的 IP 地址

笔者简化了 update 报文的众多属性，而是仅仅实现了上面的三个公认强制属性。

Network Layer Reachability Information（网络层可达信息）:

这个变长域包含了 IP 地址前缀的清单。网络层可达信息的字节长度不是明确编码的，但是可以计算如下：

UPDATE 报文长度-23-总的路径属性长度-不可用路由长度。

其中 UPDATE 报文长度是定长 BGP 报文头的编码值，总的路径属性长度和不可用路由长度是作为部分 UPDATE 报文的编码值。23 是定长的 BGP 报文头，总的路径属性长度域和不可用路由长度域的组合长度。

可达信息编码时作为一个或者多个二元组格式为〈长度，前缀〉，它们的域描述如下：

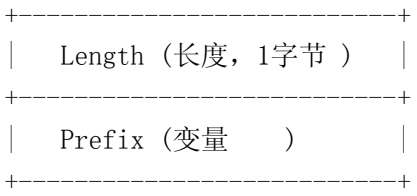

域使用和含义如下：

a) 长度:

长度域指示了 IP 地址前缀的比特长度。0 地址指示了匹配所有 IP 地址的前缀（前缀本身 0 字节）

b) 前缀:

前缀域包含了 IP 地址前缀跟随足够的填充比特使=域的结尾能够落在字节边界。注意填充比特的值不关紧要。

UPDTAE 报文的最小长度是 23 字节—19 字节定长报文头+2 字节不可用路由长度+2 字节总的路径属性长度（不可用路由长度是 0 同时总的路径属性长度是 0）。

UPDATE 报文能够广播至少一条路由，路由可用几个路径属性描述。所有的路径树形包括在一个给定的 UPDATE 报文适用于在 UPDATE 报文的网络层可达信息域内包含的目的地。

一个 UPDATE 报文能够列出多个路由撤销服务。每一个路由通过目的地制定（表示为 IP 前缀），明白的根据上下文指定了 BGP 发言者-BGP 发言者连接先前广播过的路由

一个 UPDATE 报文可以仅仅撤销路由，这样就不需要包括路径属性或者网络层可达信息。相反，也可以仅仅广播可达路由，这样 WITHDRAWN ROUTES 不需要了

2.2.4 KEEPALIVE 报文格式

BGP 不使用任何基于传输协议的心跳机制来确定对端是否可达。相反，KEEPALIVE 报文在对端之间交换频率要满足 HOLD 计时器不溢出的标准。合理的最大 KEEPALIVE 报文时间是 HOLD 计时器间隔的 1/3。KEEPALIVE 报文必须不能比每秒一个更频繁。应用可以调整发送 KEEPALIVE 报文的速率使用 HOLD 计时间隔的函数。

如果商议哦 HOLD 计时间隔是 0，周期性的 KEKPALIVE 报文必须不发送。

KEEPALIVE 报文只包含报文头长度是 19 字节。

2.2.5 NOTIFACATION 报文格式

NOTIFACATION 报文在探测到错误情况时发送。BGP 连接发送他之后要立即关闭。除了顶长 BGP 报文头，NOTIFICATION 报文包括下面的域。

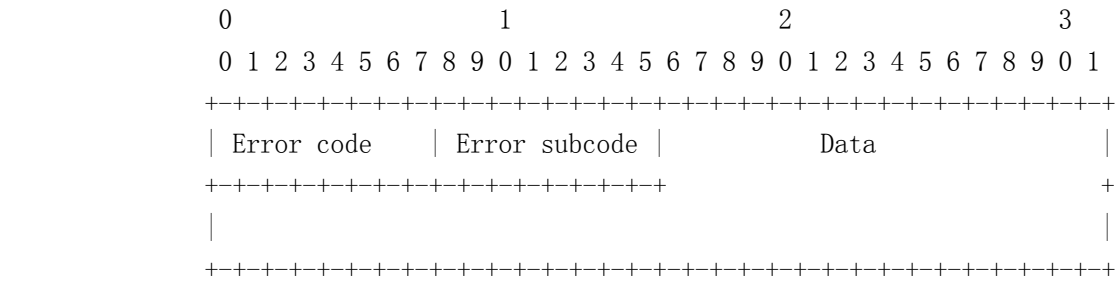

错误码:

1 字节的无符号整数指示了 NOTIFICATION 的类型。下列的错误类型编码定义：

错误码	符号名称
1	报文头错误
2	OPEN 报文错误
3	UPDATE 报文错误
4	Hold 计时器溢出

5 FSM 错误

6 终止

错误子码：在这里不赘述，详细可参见 rfc1771 文档。

2.3 路径属性使用

BGP 的 UPDATE 报文的路由属性承载了路由器之间交流的众多信息，为建立了 BGP 协议的路由器之间进行修改路由起到了不可估量的作用。下面针对于 3 个重要的公认强制属性来说明。

2.3.1 ORIGIN

ORIGIN 式是一个公认强制属性。ORIGIN 属性是产生路由的自治系统产生的。所有选择通告路由到别的 BGP 发言者的 BGP 发言者可以把这个包括在 UPDATE 报文内。

2.3.2 AS-PATH

AS-PATH 是公认强制属性。本属性定义了 UPDATE 报文那的路由信息经过的 AS。列表的元素可以是 AS_SET 或者 AS_SEQUENCE。

当 BGP 发言者通告从别的 BGP 发言者 UPDATE 的报文学习到的路由，应该根据路由发送到的 BGP 发言者的位置，修改路由 AS-PATH 的属性。

a)当给定的 BGP 发言者通告路由到本 AS 的别的 BGP 发言者，通告发言者应该修改路由的 AS-PATH 属性。

b)当给定的 BGP 发言者通告路由到邻居 AS 的 BGP 发言者，通告发言者因该修改路由的 AS-PATH 属性。

1）如果 AS-PATH 的第一个路径属性是 AS-SEQUENCE 类型，本地系统应该把字节的 AS 号码作为序列的最后一个 AS 号码加在后面（放在最左面）。

2）如果 AS-PATH 的第一个属性类型是 AS-SET 类型，本地系统应该添加一个新的路径段 AS-SEQUENCE 类型，在段的内部放 AS 号码。

当 BGP 发言者产生路由：

a)起源发言者应该包括自己的AS号码在发送到邻居AS自治系统的BGP发言者的所有UPDATE报文的AS-PATH属性中。(在这种情况下,起源发言者的自治系统号因该是AS-PATH属性的入口)。

b)起源发言者因该包括一个空的 AS-PATH 属性在发送到本地自治系统的 BGP 发言者的所有UPDATE报文的AS-PATH属性中。(空的AS-PATH属性是长度域是0的属性)

2.3.3 NEXT-HOP

NEXT-HOP 路径属性定义了边界路由器的 IP 地址，作为到达 UPDATE 报文的目的地列表的下一跳。如果边界路由器和对端属于同一个 AS，对端是内部边界路由器。否则，是外部边界路由器。BGP 发言者可以通告任何内部边界路由器作为下一跳，如果本边界路由器和 IP 地址对应的接口（说明在 NEXT-HOP 路径属性中）和本地以及远端边界路由器共享公共的子网。BGP 发言者可以通告任何外部边界路由器作为下一跳，如果本边界路由器的 IP 地址是通过对端 BGP 发言者学习到的，同时边界路由器的 IP 地址相应的接口（在 NEXT-HOP 路径属性中说明）和本地以及远端的 BGP 发言者共享了公共的子网。BGP 发言者需要能够支持外部边界路由器的通告能力不足。

BGP 发言者必须不通告对端的一个地址作为 NEXT-HOP 到这个对端，作为这个发言者产生的路由。BGP 发言者必须不能安装路由把自己作为下一跳。

当 BGP 发言者通告路由到本地 AS 的 BGP 发言者，通告发言者不应该修改路由的 NEXT-HOP 属性。当 BGP 发言者通过内部链路受到路由，可以转发包到 NEXT-HOP 地址，如果属性中包含的地址是和本地以及远端 BGP 发言者在公共的子网上。

2.4 BGP 有限状态机

BGP 主要包含下表中的六个状态:

1 - Idle	4 - OpenSent
2 - Connect	5 - OpenConfirm
3 - Active	6 - Established

开始 BGP 在 Idle 状态。

2.4.1 Idle 状态

在这个状态，BGP 拒绝任何进入的 BGP 连接。不为对端分配任何资源。响应 Start 事件（系统或者操作者初始化），本地系统初始化所有的 BGP 资源，开始 ConnectRetry 计时器，初始化传输连接到别的 BGP 对端，当检听到远端 BGP 对端初始化 BGP 连接，改变状态到连接。ConnectRetry 计时器的确切值是本地设置，但是要有效大于允许 TCP 初始化。

如果 BGP 发言者探测到错误，关闭连接转换状态到 Idle。脱离 Idle 状态需要 Start 事件的产生。如果这个事件自动产生，连续的 BGP 错误会导致发言者的抖动。为了避免这个情况，建议先前由于错误而转换到 Idle 状态的对端的 Start 事件不应该立即产生。在连续产生的 Start 事件之间的时间，如果事件时自动产生的，应该指数增长。初始计时器的值应该是 60 秒。计时应该每连续产生一次就加倍。

在 Idle 状态下任何别的事件被忽略。

2.4.2 连接状态

在这个状态 BGP 等待传输协议连接的完成。

如果传输协议连接成功，本地系统清除 ConnectRetry 计时器，完成初始化，发送 OPEN 报文到对端，改变状态到 OpenSent.

如果传输协议连接失败（比如，重穿超时），本的系统重启 ConnnectRetry 计时器，继续侦听远端 BGP 对端初始化的连接，改变它的状态到 Active 状态。

响应 ConnectRetry 计时器溢出事件，本地系统重启 ConnectRetry 计时器，初始化传输连接到 BGP 对端，继续侦听远端 BGP 对端初始化的连接，停留在 Connect 状态。

Start 事件在 Active 状态被忽略。

响应其他的事件（被别的系统或者操作者初始化），本地系统释放连接占有的所有的 BGP 资源，转换状态到 Idle。

2.4.3 Active 状态

在这个状态，BGP 尝试通过初始化传输协议连接来得到对端。

如果传输协议连接成功，本地系统清除 ConnectRetry 计时器，完成初始化，发送 OPEN 报文到对端，设置 Hold 计时器为一个很大值，改变状态到 OpenSent。计时器值建议是 4 分钟。

响应 ConnectRetry 计时器溢出事件，本的系统重启 ConnectRetry 计时器，初始化传输连接到别的 BGP 对端，继续侦听远端 BGP 对端初始化的连接，改变状态到 Connect.

如果本的系统探测到远端尝试建立 BGP 连接到自己，远端的 IP 地址不是期望的，本的系统重启 ConnectRetry 计时器，拒绝尝试连接，继续侦听远端 BGP 对端初始化的连接，停留在 Active 状态。

Start 事件在 Active 状态被忽略。

响应任何别的事件（别的系统或者操作者初始化），本的系统释放连接占有的所有的资源，改变状态到 Idle.

2.4.4 OpenSent 状态

在这个状态 BGP 等待来自对端的 OPEN 报文。当 OPEN 报文受到，所有的域要检查正确性，如果 BGP 报文头检查或者 OPEN 报文检查探测到错误（见部分 6。2），或者由连接冲突（见部分 6。8），本的系统发送 NOTIFACATION 报文，改变状态到 Idle。

如果在 OPEN 报文内没有错误，BGP 发送 KEEPALIVE 报文设置 KeepAlive 计时器。Hold 计时器，先前被设置为一个大值（见上面），被商议的 Hold Time 值替代（见部分 4。2）。如果商议的 Hold Time 值是 0，Hold Time 计时器和 KeepAlive 计时器要重启。如果 Autonomous System 域的值是和本地 AS 号码一样的，连接是“内部”连接，否则是“外部”连接。（这会影响下面所描述的 UPDATE 报文的处理。）最后，转态转换到 OpenConfirm。

如果从承载传输协议收到断开通告，本的系统关闭 BGP 连接，重启 ConnectRetry 计时器，同时继续侦听远端 BGP 初始化的连接，进入 Active 状态。

如果 Hold 计时器溢出，本的系统发送 NOTIFICATION 报文，错误码是 Hold Timer Expired ，同时改变状态到 Idle。

响应 Stop 事件（系统或者操作者初始化），本地系统发送 NOTIFICATION 报文，错误码是 Cease 同时改变状态到 Idle。

Start 事件在 OpenSent 状态被忽略。

对别的事件的响应，本的系统发送 NOTIFICATION 报文，错误码是 Finite State Machine Error 同时改变状态到 Idle。

无论何时 BGP 改变状态从 OpenSet 道 Idle,关闭 BGP（以及传输层）连接释放连接占用的所有的资源。

2.4.5 OpenConfire 状态

在这个状态，BGP 等待 KEEPALIVE 或者 NOTIFICATION 报文。

如果本的系统受到 KEEPALIVE 报文，改变状态到 Established。

如果在收到 KEEPALIVE 报文之前，Hold 计时器溢出，本的系统发送 NOTIFICATION 报文，错误码是 Hold Timer Expired，改变状态到 Idle.

如果本的系统受到 NOTIFICATION 报文，改变状态到 Idle。

如果 KeepAlive 计时器溢出，本的系统发送 KEEPALIVE 报文，重启他的 KeepAlive 计时器。

如果从底层的传输协议受到断开通告，本的系统状态转换到 Idle。

响应 Stop 事件（系统或者操作者初始化）本地系统发送 NOTIFICATION 报文，错误码是 Cease ，改变状态到 Idle。

Start 事件在 OpenConfirm 状态被忽略。

响应别的事件，本的系统发送 NOTIFICATION 报文，错误码是 Finite State Machine Error，改变状态到 Idle。

无论何时 BGP 改变状态从 OpenConfirm 到 Idle，关闭 BGP（传输层）连接同时释放所有连接占用的资源。

2.4.6 建立状态

在建立状态，BGP 交换 UPDATE, NOTIFICATION,和 KEEPALIVE 报文到对端。

如果本的系统受到 UPDATE 或者 KEEPALIVE 报文，开启 Hold 计时器，如果商议的 Hold Time 值不是零。

如果本的系统受到 NOTIFICATION 报文，状态转换到 Idle.

如果本的系统受到 UPDATE 报文，UPDATE 报文的错误处理过程（见部分 6。3）探测到错误，本的系统发送 NOTIFICATION 报文，改变状态到 Idle。

如果断开通告通过承载传输协议受到，本的系统改变状态到 Idle。

如果 Hold 计时器溢出，本的系统发送 NOTIFICATION 报文，错误码是 Hold Timer Expired ，改变状态到 Idle。

如果 KeepAlive 计时器溢出，本的系统发送 KEEPALIVE 报文，重启 KeepAlive 计时器。

每次本的系统发送 KEEPALIVE 或者 UPDATE 报文，重启 KeepAlive 计时器，除非商议的计时器值是零。

响应 Stop 事件（通过系统或者操作者初始化），本地系统发送 NOTIFICATIOIN 报文，错误码是 Cease，改变状态到 Idle。

Start 事件在 Established 状态被忽略。

响应别的事件，本的系统发送 NOTIFACATION 报文，错误码是 Finite State Machine Error，改变状态到 Idle。

无论何时 P 改变状态从 Established 到 Idle，关闭 BGP（以及传输层）连接，释放连接占用的所有资源，删除所有的连接产生的路由。

2.4.7 状态图

对于 BGP 状态机的转换可简要的使用下面的状态图描述

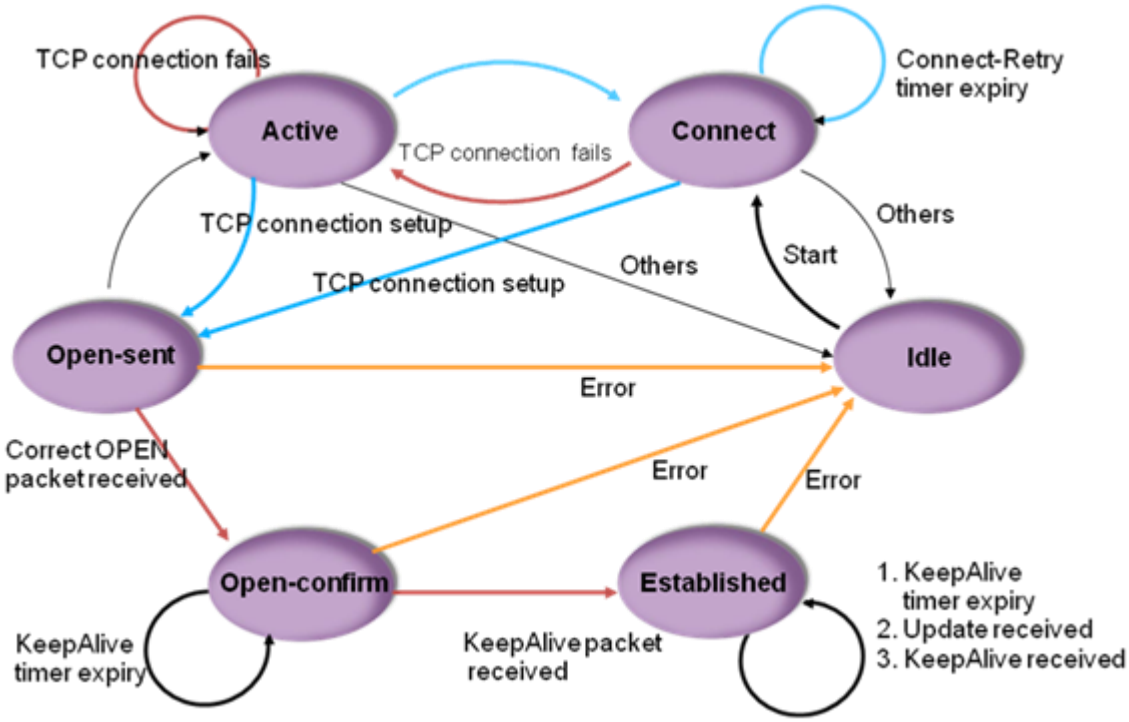

图 1：BGP 有限状态机

2.4.8 BGP 的事件

BGP 的十三个事件:

1 - BGP Start	8 - Hold Timer expired
2 - BGP Stop	9 - KeepAlive timer expired
3 - BGP Transport connection open	10 - Receive OPEN message
4 - BGP Transport connection closed	11 - Receive KEEPALIVE message
5 - BGP Transport connection open failed	12 - Receive UPDATE messages
6 - BGP Transport fatal error	13 - Receive NOTIFICATION message
7 - ConnectRetry timer expired	

对于事件和状态相互间的转化以及相互间触发的动作，在 rfc1771 文档的附录中有详细的总结，可以参考理解。

第三章 系统设计

3.1 系统总述

系统的整体设计主体上包括十三个模块和一个核心数据结构（参见下面的系统图）。十三个模块分别为 IP 报文转发模块，IP 报文监听模块，ARP 报文管理模块，网卡管理模块，路由表功能模块，路由表查找模块，BGP 报文监听模块，BGP 报文发送模块，BGP 报文解析模块，BGP 报文读取模块，BGP 报文更新模块，BGP 有限状态机管理模块和计时调度模块；一个核心的数据结构就是系统的路由表。具体的模块依赖关系参见下面的系统图。

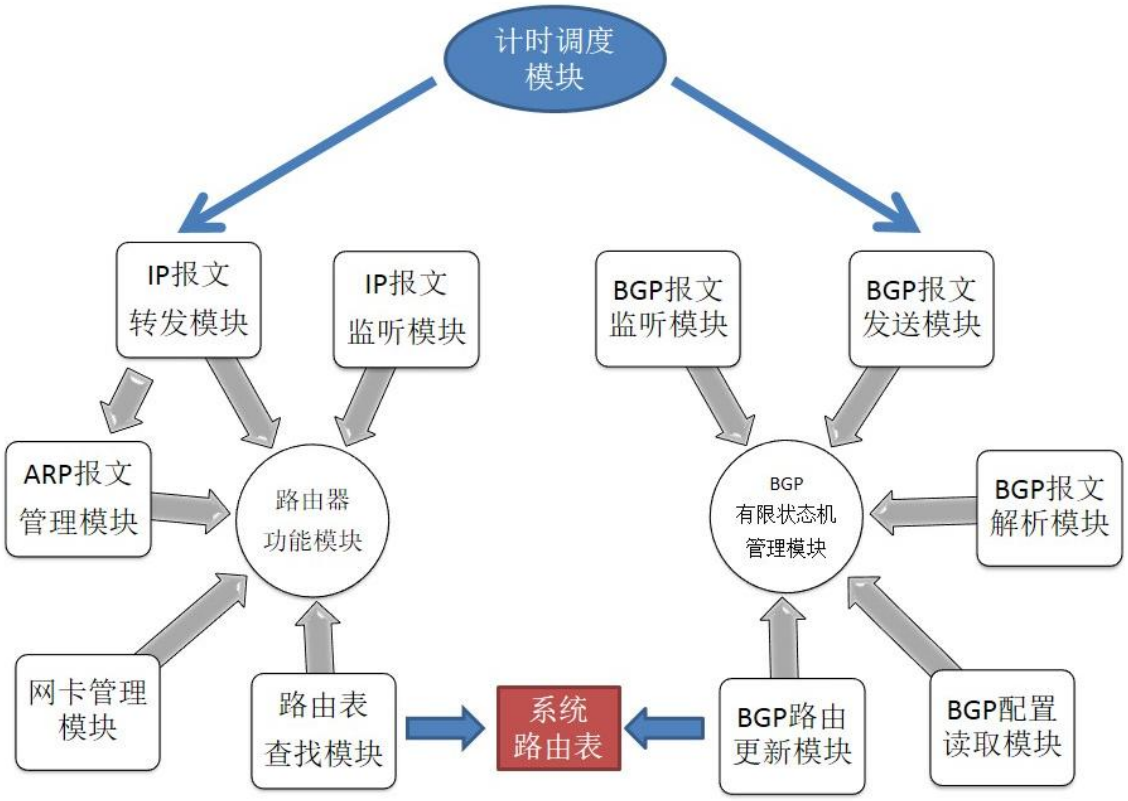

图 2：系统图

这十三个模块又可以分为三类。第一类是 IP 报文转发子系统，这一子系统是以路由器功能模块为核心，以 IP 报文转发模块，IP 报文监听模块，ARP 报文管理模块，网卡管理模块，路由表查找模块为辅助。主要完成对系统中接受到的 IP 报文进行正确的转发。第二类是 BGP 协议管理子系统，这一子系统是以 BGP 有限状态机管理模块为核心，以 BGP 报文监听模块，BGP 报文发送模块，BGP

报文解析模块，BGP 配置读取模块，BGP 报文更新模块为辅助。主要是对 BGP 协议的功能进行具体实现。第三个子系统是调度系统，主要是包括计时调度模块。这一子系统是对系统报文缓冲队列进行周期性调度的实现。

系统路由表这一数据结构是维系 IP 报文转发子系统和 BGP 协议管理子系统之间路由信息和数据交互的一个重要媒介。它是实现 BGP 协议和 IP 报文转发的重要信息交互枢纽。

3.2 IP 报文转发子系统

笔者在该课题中没有调用 Linux 内核的 IP 报文转发模块，而是自己实现了一个较为全面的 IP 报文转发系统。该 IP 报文转发子系统实现了对 Linux 的各个网卡报文进行监听，同时根据路由表进行正确地转发 IP 报文。

3.2.1 IP 报文监听模块

笔者在这个模块实现的是监听 Linux 网卡较为底层的报文，报文包括 IP 报文，ARP 报文。这个模块主要监听这两类报文，并将这两类报文交付给 IP 报文转发模块，和 ARP 报文管理模块来处理。具体可参加下面的流程图片段。

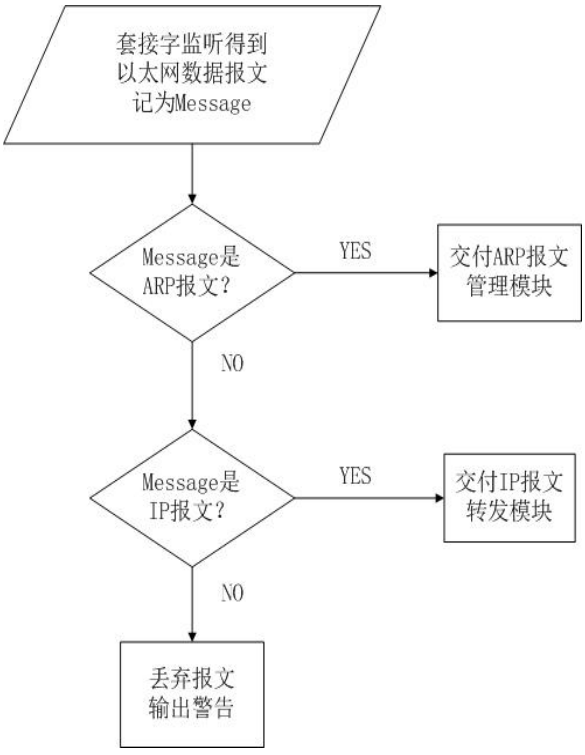

图 3：IP 监听流程片段

3.2.2 IP 报文转发模块

该模块是对 IP 报文转发，下面是转发一个报文的主要流程图。IP 报文的转发主要流程是通过路由表项判断报文是否可达，同时通过 ARP 缓存来修改 MAC 地址，在相应网卡转发，同时修改 TTL 值等相应参数。

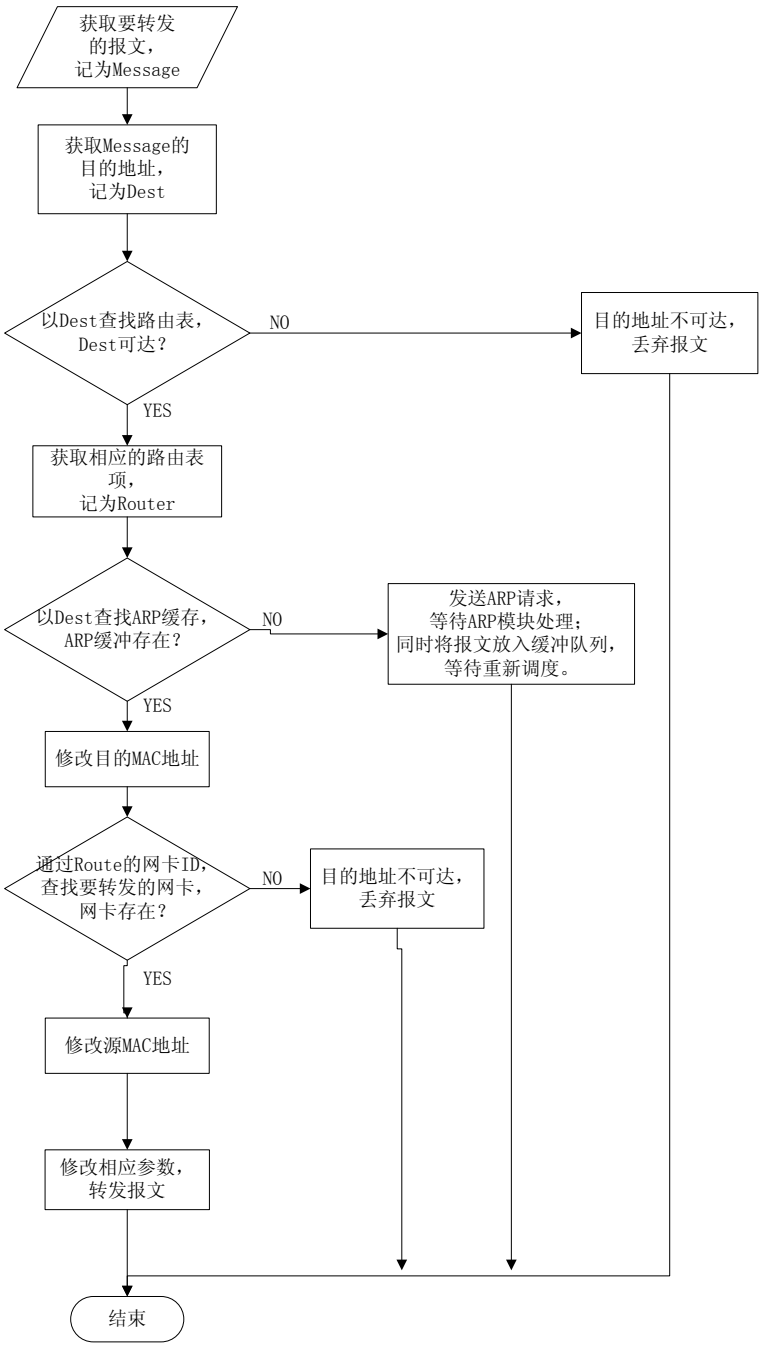

图 4：IP 报文转发流程图

3.2.3 ARP 报文管理模块

该模块是对系统的 ARP 缓存进行管理。它包括 ARP 报文的请求，ARP 报文应答的处理。同时提供查找 ARP 表项，添加 ARP 表项。为 IP 报文的转发提供了有利的工具。

图 5：ARP 功能图

3.2.4 网卡管理模块

该模块在系统启动时就读入系统的所有网卡信息，并将其缓存在相应的数据结构之中。主要是提供其他模块对网卡的查找提供一系列的工具。也为网络是否可达提供了非常有利的工具。

图 6：网卡管理图

3.2.5 路由表查找模块、

该模块是提供给一个查找路由表的接口，它为其他模块提供了访问和查询路由表的一个有利的接口。

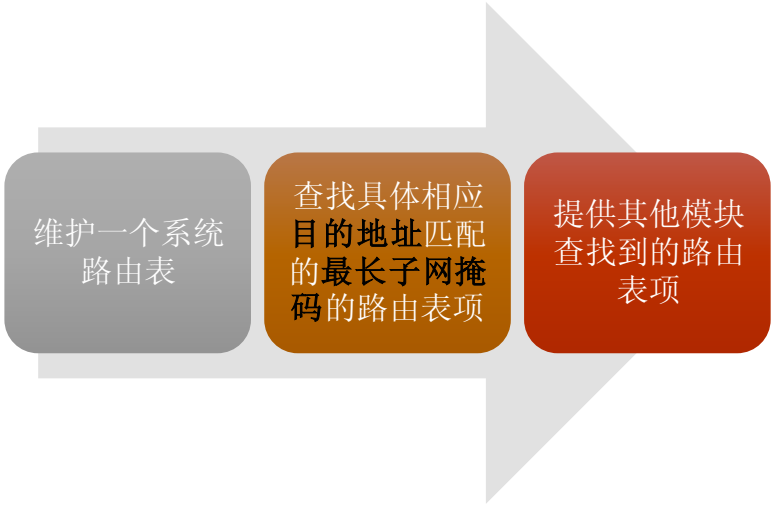

图 7：路由表查找功能图

3.2.6 路由器功能模块

该模块集成了所有其他模块的功能。它包括对路由表的管理，查找，更新；以及提供了 IP 报文的相关小工具，为路由功能提供了许多接口。

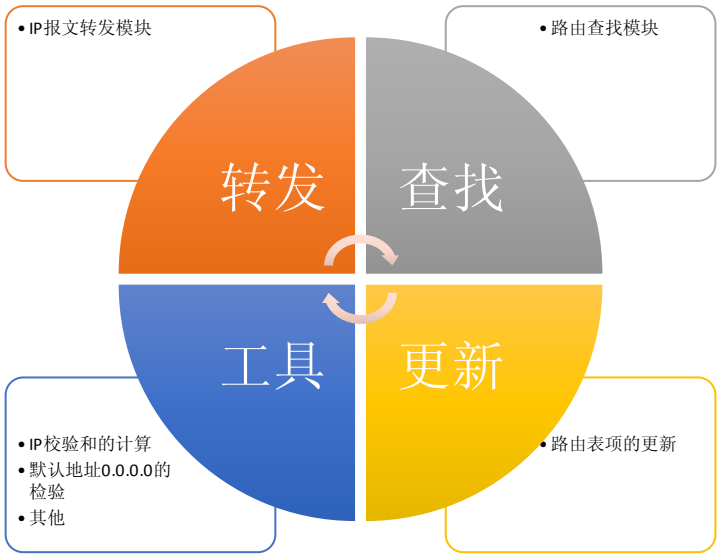

图 8：路由器功能模块图

3.3 BGP 协议管理子系统

这个子系统实现了 BGP 协议的全部功能。为和华为路由进行报文交互，对等体的状态迁移提供了良好的管理。

3.3.1 BGP 有限状态机管理模块

该模块实现了一个完整的 BGP 有限状态机（FSM）。为 BGP 对等体（Peer）的状态随着事件的迁移提供了非常明确的手段。对于 BGP 状态机的设计参照 rfc1771 文档。上文也给出了具体的分析。

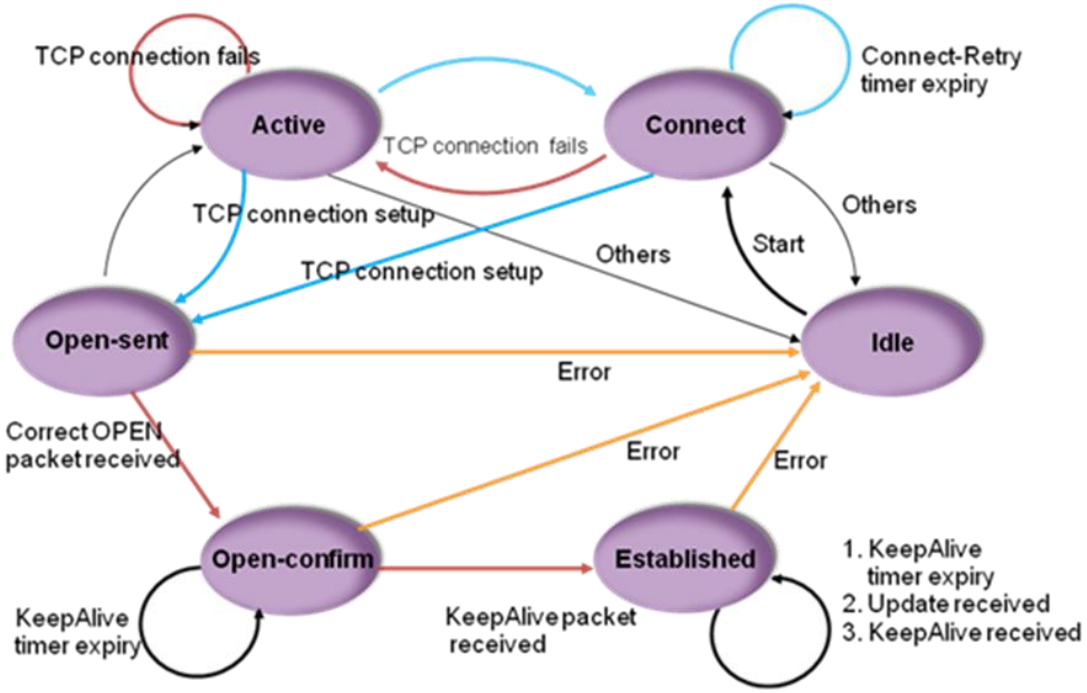

图 9：BGP 有限状态机

3.3.2 BGP 报文监听模块

该模块是监听 BGP 报文的重要模块。它主要实现了对 BGP 报文的监听，然后将监听的报文缓存的对等体的接收消息的缓存队列。

与此同时，还对消息的类型进行解析，同时触发对等体接收到相关消息的事件。对等体会对这样的事件重启一个线程做出相关的处理。

3.3.3 BGP 报文发送模块

该模块是对 BGP 报文的转发。对于报文的转发过程见下图描述。对于要转发的报文，不是直接发送，而是将报文缓存的队列中，等待计时器的调度。

图 10：BGP 报文转发模块

3.3.4 BGP 报文解析模块

该模块是对 BGP 各种报文的解析。它包括对 BGP 报文首部，OPEN 报文，UPDATE 报文，KEEPALIVE 报文，NOTIFICATION 报文的解析。

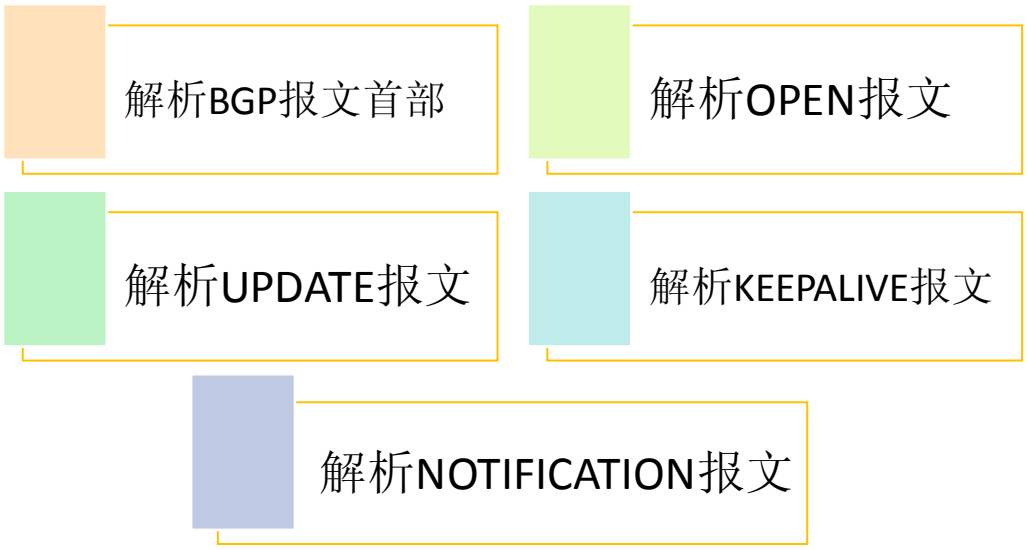

图 11：BGP 报文解析模块

3.3.5 BGP 配置读取模块

该模块是对用户的 BGP 初始配置读取并建立相应的功能。大体上的配置就是 BGP 的 AS_NUMBER, BGPID 以及 BGP 对等体所在 AS 的 AS_NUMBER 和相应的 IP 地址。

关于配置的实现是用户手动编写文本配置文件。然后系统调用相应的函数来读取用户的配置操作。

图 12：配置读取模块

关于配置文件的格式后面会有说明，这里先略去。

3.3.6 BGP 报文更新模块

当系统接收到 UPDATE 报文时，会对系统的路由表进行更新和通告其他对等体相关路由信息。该模块是完成对 BGP 报文的更新，同时对通过其他对等体 UPDATE 信息也有相应的操作。

UPDATE 的通过操作要求修改 UPDATE 信息的下一条属性，这样做事维持路由可达性，使得对等体的路由表更新可以顺利加入通告的路由表项。

具体的路由更新可以抽象为下面的流程图。

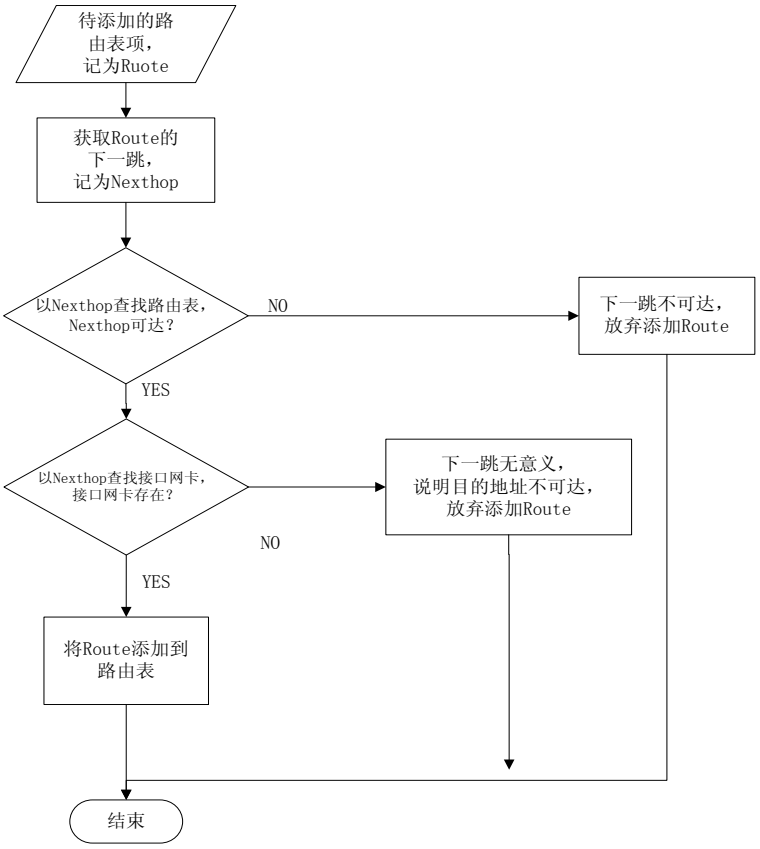

图 13：路由更新流程图

3.4 调度子系统

调度子系统是对这个系统的调度。该系统主要组成部分就是计时调度模块。

主要是对那些未能发送成功的缓存队列里面的报文进行重发。此外调度系统还要定时检验计时器是否超时。若超时，则需激发超时事件。

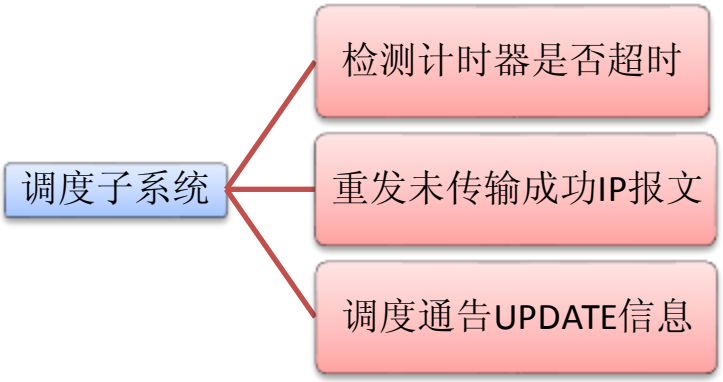

图 14：调度模块功能图

第四章 系统实现

4.1 实现总述

笔者在上面系统设计的基础上，利用 c++编程语言，在 GNU/Linux 平台上，实现了整个系统。下图是对这个工程所有实现的类的概览。

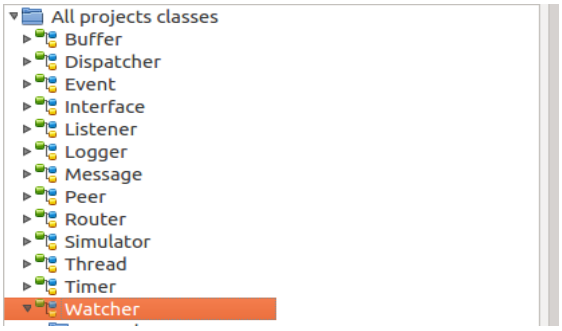

图 15：所有工程的类

对于每个类的功能以及相关的数据结构，在下面的实现说明部分将会给出具体的说明。

4.2 IP 报文转发系统

报文转发系统实现了对网卡之中的报文进行监听，对于要转发 IP 报文需要修改的 MAC 地址这一需求。这个子系统还实现了 ARP 请求报文的发送。

转发 IP 报文是这个模块的最基础的功能，对于一个特定的 IP 包的转发，可以使用 Router 类的 PacketForward 函数，并且若未转发成功，则需要将报文放到等待队列之中。

同时这个子系统需要大量地和计算机的接口进行交互，所以 Interface 类也是实现了对机器之中的管理。

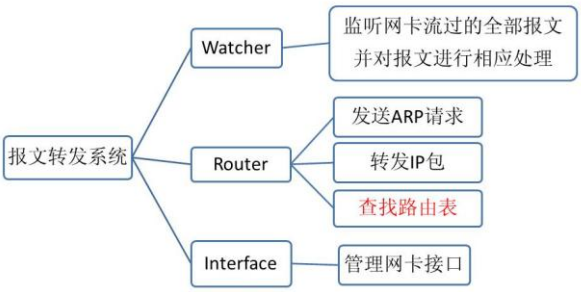

图 16：IP 报文转发功能图

4.2.1 Watcher 类

实现了对网卡的所有报文的监控以及转发的相应的处理，下面是具体实现对于监听的报文进行处理的代码片段。主要的函数是 **Watcher::StartListen()**。这个函数完成了对 ARP 报文和 IP 报文的监听。下面是具体监听的代码片段。

```
… …
switch (ntohs(pEthhdr->h_proto)) {
        case ETH_P_ARP: //  处理 arp 报文
                pArphdr = (struct eth_arphdr *) ((u_char *)pEthhdr + sizeof(struct ethhdr));
                if (CheckInter(pArphdr->ar_tip)) {// 检查目的 ip 是不是当前的网卡接口
                        g_rtr->ARPRosHandle(pArphdr);    //添加 ARP 缓存
                } else {
                        if (isDebug) {
                                g_log->Tips("arp already known");
                        }
                }
                break;
        case ETH_P_IP: // 处理 IP 报文
                pIphdr    = (struct iphdr *) (pMsg->ReadPos() + sizeof(struct ethhdr)); // IP 报头
                pTcphdr = (struct tcphdr *) (pMsg->ReadPos() +                          // TCP 报头
                                sizeof(struct ethhdr) + sizeof(struct iphdr) );
                if (!CheckInter(pIphdr->daddr)) {
                        // try to forward packet, if ip des is not in my Interface
                        if (pTcphdr->dest != htons(BGP_PORT)
                                && pTcphdr->source != htons(BGP_PORT)) {
                                g_rtr->PacketForward(pMsg); // 对于非 BGP 的 IP 报文进行转发
                        }
                }
                break;
        default:
                continue;
    }
… …
```

4.2.2 Router 类

实现了 ARP 请求和 ARP 缓存处理；IP 报文的转发；同时实现了查找路由表。主要，这里查找路由表是和 BGP 管理系统的交互点。

图 17：Router 类概览

4.2.3 Interface 类

读取网卡信息和管理网卡。在系统启动初就对网卡信息进行收集，然后提供给报文转发系统对网卡的一系列操作。

4.3 BGP 管理系统

BGP 管理系统比较复杂，下面给出一个层次图。这个图说明了 BGP 管理系统的主体实现位于 Simulator 这个模拟器类里面，Timer 是用来计时并且调度的。其它底层的类下面有说明。

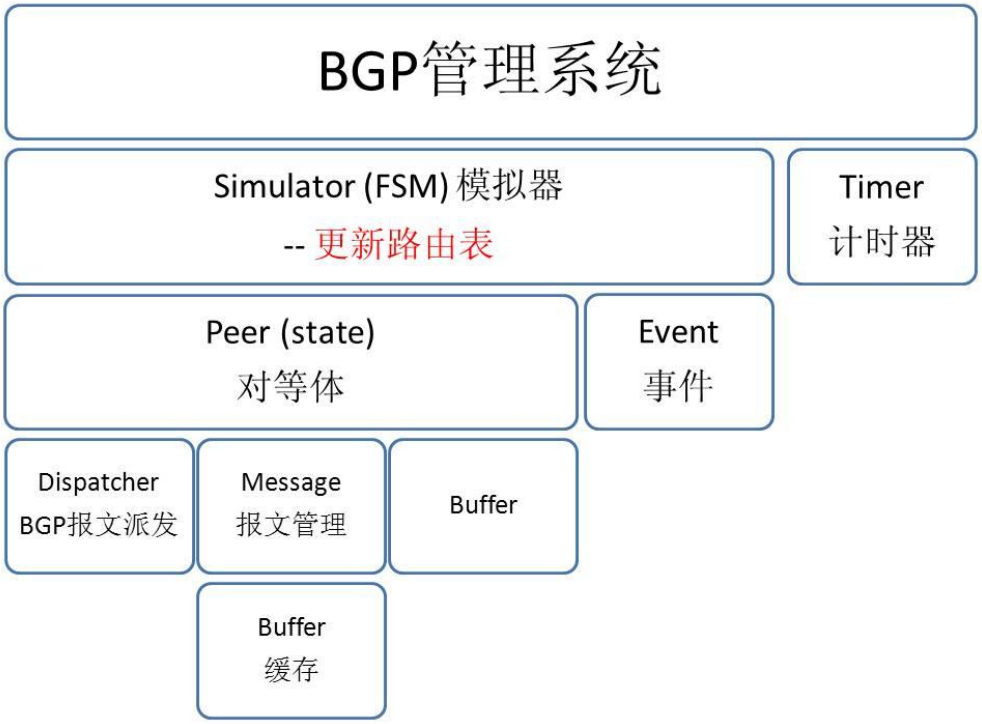

图 18：BGP 管理系统层次图

4.3.1 Simulator 类

其中的主体类是 Simulator 类，这个类实现了 BGP 的有限状态机

Simulator::FSM(Peer * pPeer, event_t eve)

同时实现了一系列对 BGP 报文解析的函数

bool ParseHeader(Peer *, u_char *, u_int16_t &, u_int8_t &);
bool ParseOpen(Peer *);
bool ParseNotification(Peer *);
bool ParseUpdate(Peer *);
bool ParseKeepalive(Peer *);

以及实现了 BGP 各类报文的发送函数

```
void SimOpen(Peer *);
void SimKeepalive(Peer *);
void AdvertUpdate(Peer *);
void TransUpdate(struct _bgp_update_info *);
void SimUpdate(Peer *, struct _bgp_update_info *);
void SimUpdate(Peer *, void *, size_t); // 更新路由表 --- 和报文转发系统的交互
void SimNotification(Peer *, u_int8_t, u_int8_t, void *, ssize_t);
```

4.3.2 Peer 类

这个类是对 BGP 对等体的信息进行收集和管理的主要的类。它存储了一个对等体生命期的所有参数，维护了发送消息队列和接受消息队列，维护了每个对等体的各个计时器。

```
queue<Message *>      qMsg; // messages to be sent to others
queue<Buffer *>       qBuf; // messages recieved from others
```

4.3.3 Dispatcher 类

激发接受到 BGP 报文的事件，通知对等体接受到报文，同时必须进行周期性的调度，以检查是否接受到 BGP 报文。

4.3.4 Timer 类

计时器类，进行周期性的调度，检查计时器是否超时。主要实现的函数如下：

void Timer::DoSchedule()

这个调度函数每秒重新唤醒一次，对系统之中的计时器进行检查，如果任意一个计时器超时，则会触发计时器超时事件。同时对缓存队列里面的报文进行重发。

4.4 数据结构

4.4.1 网卡表项

每张网卡信息是存在一个结构体 ifcon 里面，具体定义如下：

```
struct ifcon {
        u_char                  mac[ETH_ALEN];
        struct in_addr          netmask;
        struct in_addr          ipaddr;
        struct in_addr          broadcast;
        int                     ifid;
        char                    name[IFNAMSIZ];
};
```

这个结构体包含了网卡的 mac 地址，ip 地址，子网掩码，广播，以及网卡 id 和网卡名称。网卡信息可以通过 Linux 内核中的 netlink 中 socket 读入。

最终所有的网卡信息被同一存储在一个 vector 里面：

```
vector<struct ifcon *> vIntConf;
```

4.4.2 路由表项

每条路由表存储在结构体 rtcon 里面，具体定义如下：

```
struct rtcon {
    struct in_addr    dest;
    struct in_addr    nhop;
    struct in_addr    mask;
    int               ifid;
};
```

这个结构体包含路由表项的目的地址，下一跳，子网掩码以及所经过的网卡 ID。

4.4.3 ARP 表项

每条 ARP 缓存存储在结构体 arpcon 里面，具体定义如下：

```
struct arpcon {
    u_char            mac[ETH_ALEN];
    struct in_addr    ipadd;
};
```

这是一个 ip 地址和 mac 地址的二元组。

4.4.4. BGP 报文首部

```
struct bgphdr {
    u_char          marker[16];          // Marker
    u_int16_t       length;              // Length
    u_int8_t        type;                // Type
};
```

4.4.5 OPEN 报文

```
struct openmsg {
    struct bgphdr    msghdr;             // Message header
    u_int8_t        version;             // Version
    u_int16_t       myas;                // My Autonomous System
    u_int16_t       holdtime;            // Hold Time
    u_int32_t       bgpid;               // BGP Identifier
    u_int8_t        optparamlen;         // Optional Parameters Length
};
```

4.4.6 其它报文

由于其他报文没有固定结构体表示，通常是发送时直接构造。

4.4.7 UPDATE 信息结构体

这个结构体_bgp_update_info 是根据 UPDATE 报文的结构设计出来的，用来存储 UPDATE 报文的全部信息。大多数通过这个结构体可以发送路由通告，同时也能分析 UPDATE 报文。

```
struct _prefix {      // 网络前缀二元组
    u_int8_t        maskln;
    struct in_addr   ipaddr; // local host order
};

struct _path_attr_type { // 路径属性类型
    u_char           flag;
    u_char           typecode;
};
```

```
struct _as_path_segment { // AS Path 属性存储信息
    u_int8_t      type;
    u_int8_t      length;       // number of AS
    Buffer      * value;        // list of 2-octet value, in network order
};

struct _bgp_path_attr {       // BGP 路径属性结构体
    u_int8_t                                origin;
    vector<struct _as_path_segment *>    aspath;
    struct in_addr                          nhop;
};

struct _bgp_update_info {                   // UPDATE 信息结构体
    vector<struct _prefix *>     withdraw;     // Withdrawn Routes
    struct _bgp_path_attr        * pathattr;   // Path Attributes
    vector<struct _prefix *>     nlri;         // Network Layer Reachability Information
};
```

第五章 测试效果

5.1 实验组网

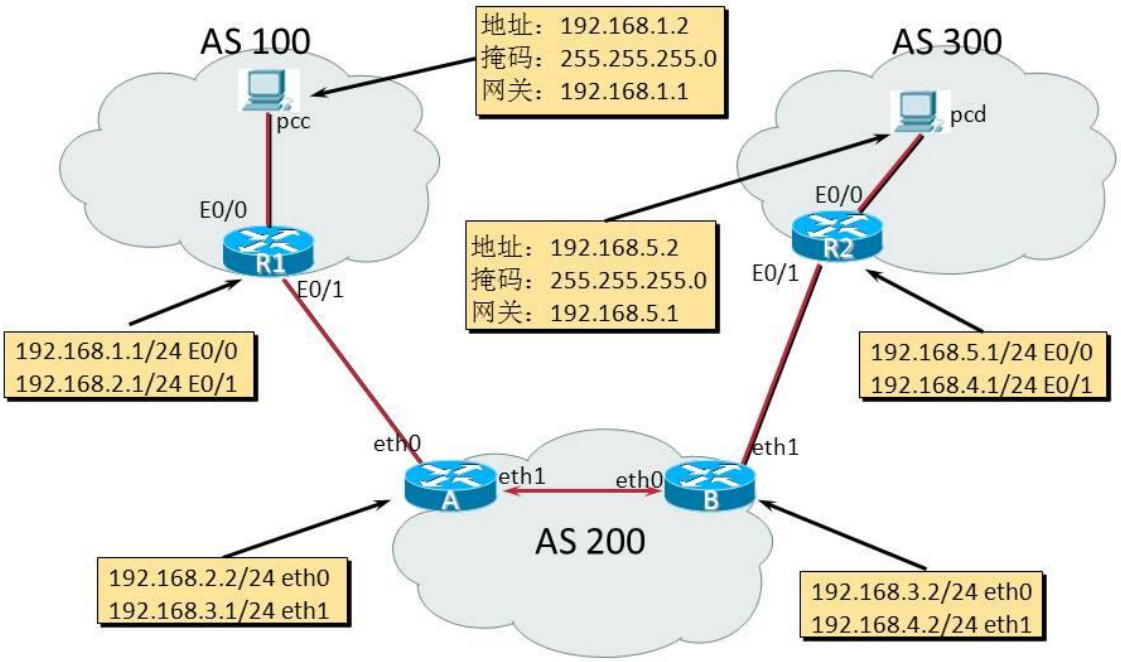

图 19：实验组网图

按照上图进行组网，设置好对于的接口信息。

图中的 pcc，pcd 是任意两台计算机。用来充当一个 AS 域里的主机。

图中的 R1 和 R2 是两台 Quidview2600 系列路由器。需要提前开启它们的 BGP 功能，用来和笔者所实现的 BGP 协议进行交互。

图中的 A，B 是一个具有双网卡的 Linux 主机，在本次实验之中充当路由器。笔者实现的 BGP 程序将在这两台计算机上运行。

最终的目的是通过 BGP 协议交互路由信息，最终 pcc 将能 ping 通 pcd。

5.2 配置内容

主机 A 网卡配置命令如下：

```
ifconfig eth0 192.168.2.2 netmask 255.255.255.0
ifconfig eth1 192.168.3.1 netmask 255.255.255.0
ifconfig eth0 promisc
ifconfig eth1 promisc
```

路由器 R1 初始化命令如下：

```
system
sysname R1
interface e0/1
ip address 192.168.2.1 24
quit
interface e0/0
ip address 192.168.1.1 24
quit
bgp 100
group nice_r1 external
peer nice_r1 as-number 200
peer 192.168.2.2 group nice_r1
network 192.168.1.2 255.255.255.0    # 设置对等体信息
quit
```

A 的 src/config/peer.conf 的内容如下：

```
200 192.168.2.1
200 192.168.3.2
100 192.168.2.2
```

第一行表示 A 的 AS_NUMBER=200， BGPID=192.168.2.1

第二行表示 A 的 peer 的 AS_NUMBER=200， IP=192.168.3.2

第二行表示 A 的 peer 的 AS_NUMBER=100， IP=192.168.2.2

其它设备的配置类似，在此不再赘述。

5.3 报文分析

从 R1 和 A 链接的端口截获的 EBGP 报文和在 A 和 B 之间截获的 IBGP 报文如下：

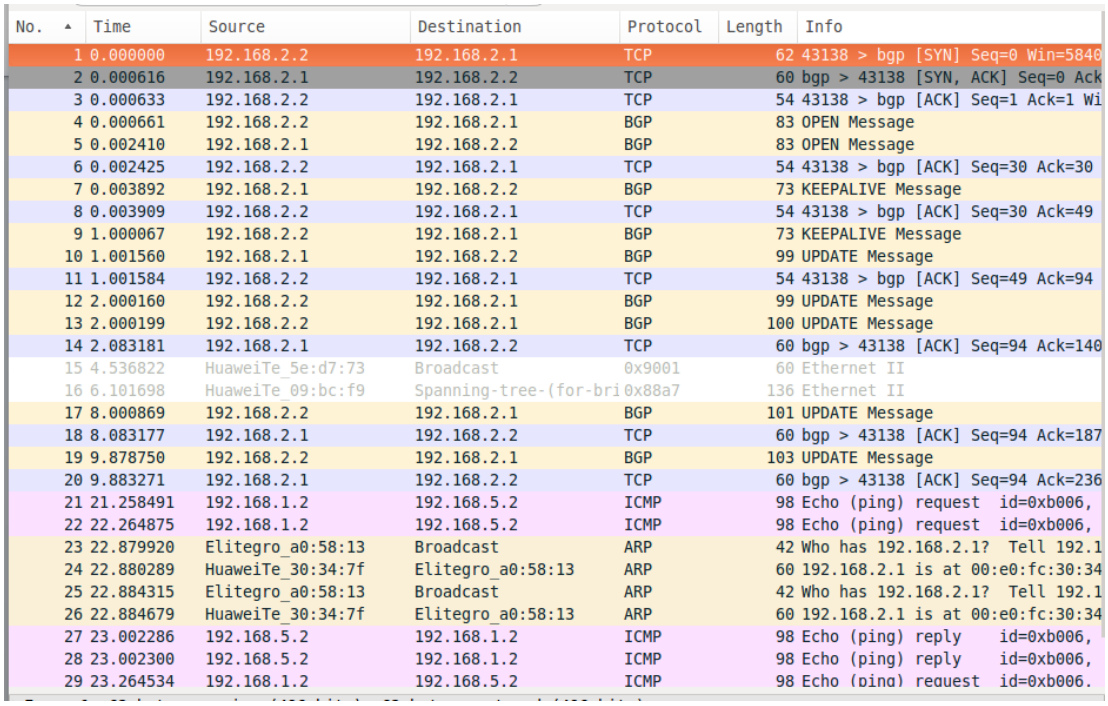

No.	Time	Source	Destination	Protocol	Length	Info
1	0.000000	192.168.2.2	192.168.2.1	TCP	62	43138 > bgp [SYN] Seq=0 Win=5840
2	0.000616	192.168.2.1	192.168.2.2	TCP	60	bgp > 43138 [SYN, ACK] Seq=0 Ack
3	0.000633	192.168.2.2	192.168.2.1	TCP	54	43138 > bgp [ACK] Seq=1 Ack=1 Wi
4	0.000661	192.168.2.2	192.168.2.1	BGP	83	OPEN Message
5	0.002410	192.168.2.1	192.168.2.2	BGP	83	OPEN Message
6	0.002425	192.168.2.2	192.168.2.1	TCP	54	43138 > bgp [ACK] Seq=30 Ack=30
7	0.003892	192.168.2.1	192.168.2.2	BGP	73	KEEPALIVE Message
8	0.003909	192.168.2.2	192.168.2.1	TCP	54	43138 > bgp [ACK] Seq=30 Ack=49
9	1.000067	192.168.2.2	192.168.2.1	BGP	73	KEEPALIVE Message
10	1.001560	192.168.2.1	192.168.2.2	BGP	99	UPDATE Message
11	1.001584	192.168.2.2	192.168.2.1	TCP	54	43138 > bgp [ACK] Seq=49 Ack=94
12	2.000160	192.168.2.2	192.168.2.1	BGP	99	UPDATE Message
13	2.000199	192.168.2.2	192.168.2.1	BGP	100	UPDATE Message
14	2.083181	192.168.2.1	192.168.2.2	TCP	60	bgp > 43138 [ACK] Seq=94 Ack=140
15	4.536822	HuaweiTe_5e:d7:73	Broadcast	0x9001	60	Ethernet II
16	6.101698	HuaweiTe_09:bc:f9	Spanning-tree-(for-bri	0x88a7	136	Ethernet II
17	8.000869	192.168.2.2	192.168.2.1	BGP	101	UPDATE Message
18	8.083177	192.168.2.1	192.168.2.2	TCP	60	bgp > 43138 [ACK] Seq=94 Ack=187
19	9.878750	192.168.2.2	192.168.2.1	BGP	103	UPDATE Message
20	9.883271	192.168.2.1	192.168.2.2	TCP	60	bgp > 43138 [ACK] Seq=94 Ack=236
21	21.258491	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006,
22	22.264875	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006,
23	22.879920	Elitegro_a0:58:13	Broadcast	ARP	42	Who has 192.168.2.1? Tell 192.1
24	22.880289	HuaweiTe_30:34:7f	Elitegro_a0:58:13	ARP	60	192.168.2.1 is at 00:e0:fc:30:34
25	22.884315	Elitegro_a0:58:13	Broadcast	ARP	42	Who has 192.168.2.1? Tell 192.1
26	22.884679	HuaweiTe_30:34:7f	Elitegro_a0:58:13	ARP	60	192.168.2.1 is at 00:e0:fc:30:34
27	23.002286	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006,
28	23.002300	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006,
29	23.264534	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006.

图 20：EBGP 报文

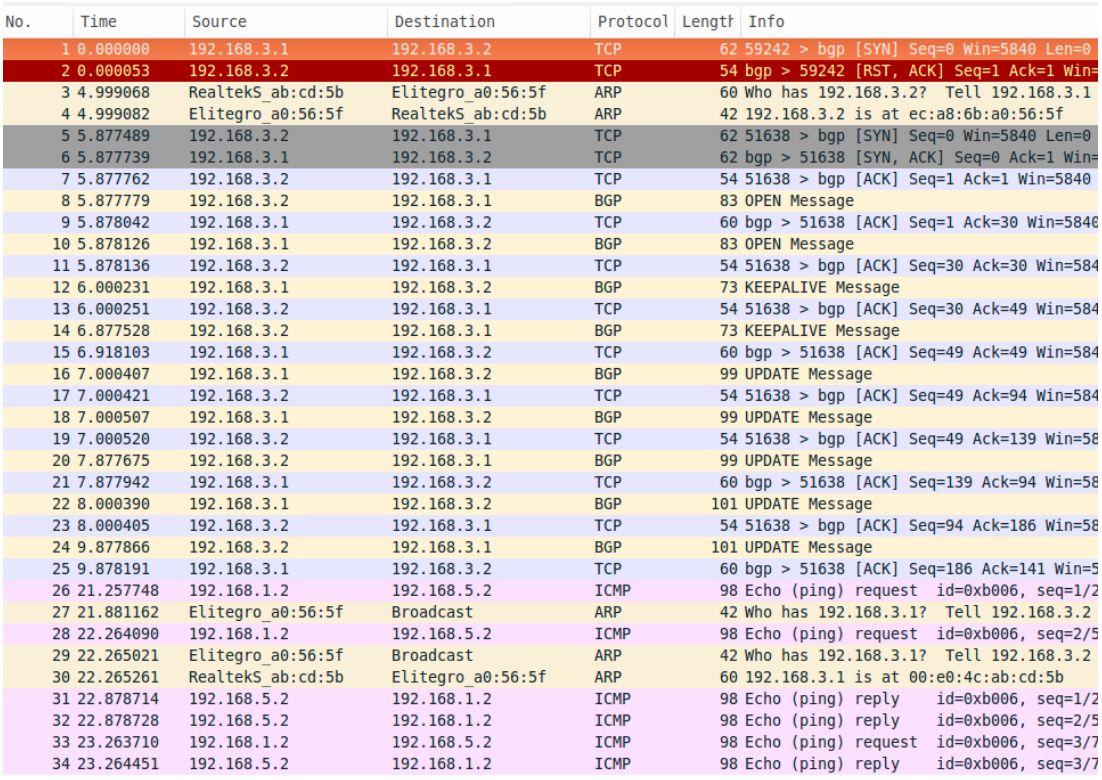

No.	Time	Source	Destination	Protocol	Length	Info
1	0.000000	192.168.3.1	192.168.3.2	TCP	62	59242 > bgp [SYN] Seq=0 Win=5840 Len=0
2	0.000053	192.168.3.2	192.168.3.1	TCP	54	bgp > 59242 [RST, ACK] Seq=1 Ack=1 Win=
3	4.999068	RealtekS_ab:cd:5b	Elitegro_a0:56:5f	ARP	60	Who has 192.168.3.2? Tell 192.168.3.1
4	4.999082	Elitegro_a0:56:5f	RealtekS_ab:cd:5b	ARP	42	192.168.3.2 is at ec:a8:6b:a0:56:5f
5	5.877489	192.168.3.2	192.168.3.1	TCP	62	51638 > bgp [SYN] Seq=0 Win=5840 Len=0
6	5.877739	192.168.3.1	192.168.3.2	TCP	62	bgp > 51638 [SYN, ACK] Seq=0 Ack=1 Win=
7	5.877762	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=1 Ack=1 Win=5840
8	5.877779	192.168.3.2	192.168.3.1	BGP	83	OPEN Message
9	5.878042	192.168.3.1	192.168.3.2	TCP	60	bgp > 51638 [ACK] Seq=1 Ack=30 Win=5840
10	5.878126	192.168.3.1	192.168.3.2	BGP	83	OPEN Message
11	5.878136	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=30 Ack=30 Win=584
12	6.000231	192.168.3.1	192.168.3.2	BGP	73	KEEPALIVE Message
13	6.000251	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=30 Ack=49 Win=584
14	6.877528	192.168.3.2	192.168.3.1	BGP	73	KEEPALIVE Message
15	6.918103	192.168.3.1	192.168.3.2	TCP	60	bgp > 51638 [ACK] Seq=49 Ack=49 Win=584
16	7.000407	192.168.3.1	192.168.3.2	BGP	99	UPDATE Message
17	7.000421	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=49 Ack=94 Win=584
18	7.000507	192.168.3.1	192.168.3.2	BGP	99	UPDATE Message
19	7.000520	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=49 Ack=139 Win=58
20	7.877675	192.168.3.2	192.168.3.1	BGP	99	UPDATE Message
21	7.877942	192.168.3.1	192.168.3.2	TCP	60	bgp > 51638 [ACK] Seq=139 Ack=94 Win=58
22	8.000390	192.168.3.1	192.168.3.2	BGP	101	UPDATE Message
23	8.000405	192.168.3.2	192.168.3.1	TCP	54	51638 > bgp [ACK] Seq=94 Ack=186 Win=58
24	9.877866	192.168.3.2	192.168.3.1	BGP	101	UPDATE Message
25	9.878191	192.168.3.1	192.168.3.2	TCP	60	bgp > 51638 [ACK] Seq=186 Ack=141 Win=5
26	21.257748	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=1/2
27	21.881162	Elitegro_a0:56:5f	Broadcast	ARP	42	Who has 192.168.3.1? Tell 192.168.3.2
28	22.264090	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=2/5
29	22.265021	Elitegro_a0:56:5f	Broadcast	ARP	42	Who has 192.168.3.1? Tell 192.168.3.2
30	22.265261	RealtekS_ab:cd:5b	Elitegro_a0:56:5f	ARP	60	192.168.3.1 is at 00:e0:4c:ab:cd:5b
31	22.878714	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=1/2
32	22.878728	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=2/5
33	23.263710	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=3/7
34	23.264451	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=3/7

图 21：IBGP 报文

最终测试 pcc 和 pcd 能互相 ping 通。

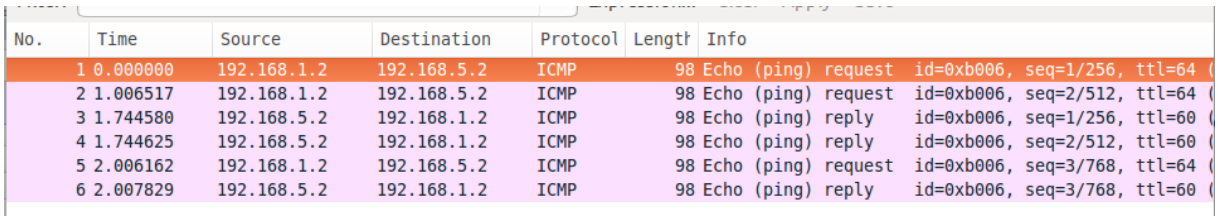

No.	Time	Source	Destination	Protocol	Length	Info
1	0.000000	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=1/256, ttl=64
2	1.006517	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=2/512, ttl=64
3	1.744580	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=1/256, ttl=60
4	1.744625	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=2/512, ttl=60
5	2.006162	192.168.1.2	192.168.5.2	ICMP	98	Echo (ping) request id=0xb006, seq=3/768, ttl=64
6	2.007829	192.168.5.2	192.168.1.2	ICMP	98	Echo (ping) reply id=0xb006, seq=3/768, ttl=60

图 22：pcc 上截获的 icmp 报文

同时 R1 和 R2 的路由表可以看出通过 BGP 学习得到的路由表项。下图是 R1 的表项，可以看出到 192.168.5.0/24 的路由表项是通过 BGP 学得到的。

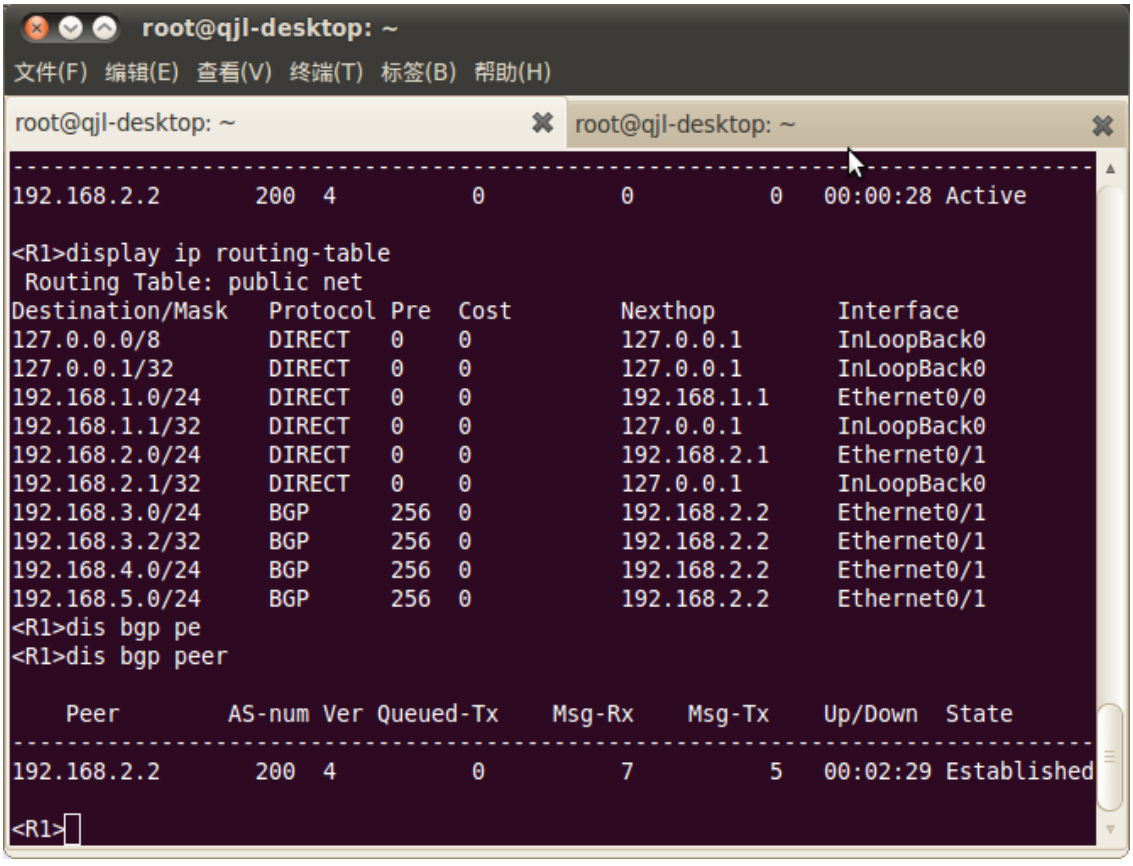

图 23：R1 的最终路由表

5.4 测试结论

由此可以得出实现的 BGP 协议正确运行。

个人总结

笔者通过大约三个月的学习 BGP 协议和实现了这个课题。

四月份期间，笔者通读了 BGP 的 rfc1771 文档。刚开始对 rfc1771 的那些 BGP 报文知识和路由属性是一知半解，感觉一个浩大的课题无法入手。然后，笔者学习学长的一个实现，突然茅塞顿开，开始架构起了属于自己工程课题。同时也改善了一些学长的设计缺陷。

四月末，笔者开始编码，从零开始编码，到七月初最终编写的 4600 多行 c++代码实现了 BGP 协议。期间当然是受益良多，比如学习了 Linux 下的套接字编程，体会的 Linux 下的 netlink 套接字的强大，学会了多线程程序的一些调试技巧，更加深入了解了如 ARP，IP 协议的精髓。同时也感慨那些设计这些协议的作者的智慧与汗水。

笔者非常感谢最后期间在实验室调试时张老师给的指导和帮助。每次总是在笔者想要放弃时候，老师的一句话让我找到了一条可以走下去的新的道路。其实学习本来就是这样，在跌倒中不断前进，最终才能达到所期待的目标。

笔者将课题的开发全过程的代码放在了 CSDN 的课题托管上（没放在 github 上是因为 csdn 速度快些），现在回头看着自己开发过程的 git 提交路线，突然感觉自己真的走了好远，同时也学到了许多。自己的努力不是白费。一分耕耘，一分收获。希望这份宝贵的经历能够激励自己在以后的学习或工作中不断前进。

参考文献及网址

[1] 计算机网络实验教程 钱德沛 高等教育出版社

[2] TCP/IP 详解 (美)W.R.史蒂文斯(W.RichardStevens)著机械工业出版社

[3] RFC1771 http://www.rfc-editor.org/rfc/rfc1771.txt

[4] UNIX 环境高级编程 (美)W.R.史蒂文斯(W.RichardStevens)著，人民邮电出版社

[5] UNIX 网络编程，卷一：套接字联网 API（第三版）(美)W.R.史蒂文斯(W.RichardStevens)著，人民邮电出版社

[6] Border Gateway Protocol (BGP) http://www.inetdaemon.com/tutorials/internet/ip/routing/bgp/index.shtml

[7] netlink socket 编程实例 http://blog.chinaunix.net/uid-14753126-id-2983915.html

[8] Linux 原始套接字实现分析 http://blog.chinaunix.net/uid-27074062-id-3388166.html

[9] Linux 多线程编程（不限 Linux） http://www.cnblogs.com/skynet/archive/2010/10/30/1865267.html